Análisis Exploratorio y Modelado Predictivo
de Costes Médicos de una Aseguradora

1. Vista previa del cuaderno Jupyter

El cuaderno Jupyter (aseguradora.ipynb) estructura el análisis en dos grandes bloques, ejecutados sobre Apache Spark (PySpark y pandas-on-Spark):

1. **Análisis Exploratorio de Datos (EDA)**: carga del dataset, verificación de nulos, categorización del BMI, análisis univariante/bivariante, identificación de outliers y respuesta a la pregunta de negocio sobre la carga financiera según el índice de masa corporal.
2. **Modelo de Regresión Lineal**: pipeline de transformación (StringIndexer, OneHotEncoder, VectorAssembler, StandardScaler) y entrenamiento de un modelo de regresión lineal con MLlib para predecir la variable charges.

El entorno utiliza Java 17, PySpark 3.5.1 y librerías de visualización (matplotlib, seaborn). El flujo es: configuración de Spark → lectura del CSV → EDA → pipeline de features → train/test split → entrenamiento → evaluación (RMSE y R^2).

Objetivo principal del análisis: averiguar, según el índice de masa corporal, qué categoría de personas ejerce mayor carga financiera a la aseguradora.

2. Resumen del dataset

El fichero insurance.csv contiene 1.338 registros de beneficiarios de una aseguradora médica. Cada fila representa a un asegurado con sus características demográficas, de salud y el coste médico asociado (charges).

Estructura y variables

Columna	Descripción
age	Edad del asegurado (años). Rango: 18–64. Media ≈ 39,2
sex	Sexo: male / female (distribución casi equilibrada: 676 / 662)
bmi	Índice de masa corporal. Media ≈ 30,7 (cerca del umbral de obesidad)
children	Número de hijos/dependientes cubiertos (0–5). Media ≈ 1,09
smoker	Fumador: yes / no. No fumadores ≈ 1.064; fumadores ≈ 274 (~20 %)
region	Región de residencia: southeast, southwest, northwest, northeast
charges	Coste médico anual en dólares. Media ≈ 13.270; máximo ≈ 63.770

Estadísticos principales de charges:

- Mínimo: 1.121,87 $ | Percentil 25: 4.740 $ | Mediana: 9.382 $
- Percentil 75: 16.640 $ | Máximo: 63.770 $
- Desviación estándar elevada (~12.110 $), coherente con la fuerte asimetría a la derecha de la distribución.

-

3. Explicación de la limpieza del EDA

A diferencia de muchos datasets reales, insurance.csv se presenta en un estado muy limpio, lo que simplifica la fase de preparación:

3.1. Valores nulos

Se comprobó la existencia de valores nulos en todas las columnas (df.isnull().sum()). El resultado fue cero nulos en age, sex, bmi, children, smoker, region y charges. No fue necesaria ninguna imputación.

3.2. Creación de variable derivada para la pregunta de negocio

Se definió la función categorizar_imc para transformar el BMI continuo en cuatro categorías clínicas estándar:

- Bajo_peso: BMI ≤ 18,5
- Peso_normal: 18,5 < BMI ≤ 24,9
- Sobrepeso: 24,9 < BMI ≤ 29,9
- Obesidad: BMI > 29,9

Esta columna categórica (bmi_category) permite agregar los costes por grupo de peso y responder directamente a la pregunta de negocio. No se eliminaron filas ni se aplicaron filtros de calidad adicionales; el dataset se consideró listo para el análisis exploratorio y el modelado.

4. Explicación de análisis univariable y bivariable

Se exploraron las distribuciones individuales y las relaciones entre variables clave para entender el perfil de los asegurados y los drivers del coste.

4.1. Distribución de cargos médicos (charges)

El histograma de charges muestra una distribución fuertemente sesgada a la derecha. La gran mayoría de los beneficiarios genera gastos relativamente bajos (por debajo de 15.000 $). La cola derecha corresponde a un grupo reducido de pacientes con costes extremos (superiores a 30.000 $ e incluso por encima de 60.000 $). Esta asimetría es típica en datos de seguros médicos y justifica el uso de métricas robustas y de modelos que no asuman normalidad estricta.

4.2. Distribución del índice de masa corporal (BMI)

La distribución del BMI es aproximadamente normal, con media y mediana situadas alrededor de 30. Esto indica que una proporción importante de la población se encuentra en el límite o por encima del umbral de obesidad.

4.3. Proporción de fumadores

Una mayoría clara de los beneficiarios no fuma. Los fumadores representan aproximadamente una quinta parte del total (~20 %). Pese a ser minoritarios, su impacto en los costes es desproporcionado, como se verá en el análisis bivariado.

4.4. Distribución de categorías de BMI

Más de la mitad de la población del seguro se clasifica en obesidad, seguida del grupo de sobrepeso. Las personas con peso normal son menos frecuentes y las de bajo peso constituyen una fracción minúscula. Esta composición demográfica ya anticipa una carga financiera elevada vinculada al exceso de peso.

4.5. Relación fumador vs. costes

El análisis comparativo muestra que el coste mínimo de un fumador es superior al coste promedio de un no fumador. El tabaquismo eleva de forma radical los gastos médicos y se configura como el factor de mayor impacto individual sobre charges.

4.6. Interacción BMI × fumador

El diagrama de dispersión BMI vs. charges, coloreado por condición de fumador, revela dos patrones: los no fumadores mantienen costes bajos y relativamente estables aunque el BMI aumente; los fumadores presentan costes sistemáticamente altos. Además, la nube de puntos de alto coste (por encima de 30.000 $) se concentra precisamente donde el BMI supera 30 (obesidad). La combinación de ser fumador y tener obesidad multiplica el gasto médico de forma muy notable.

5. Explicación de identificación de outliers

Se utilizaron diagramas de caja (boxplots) y el criterio visual de valores extremos para detectar outliers en BMI y en charges:

5.1. Outliers en BMI

Se identificaron pocos valores atípicos. Corresponden a asegurados con BMI superior a 45, es decir, obesidad extrema u obesidad mórbida. Aunque son poco numerosos, estos casos pueden generar costes sanitarios especialmente elevados y merecen atención clínica y actuarial.

5.2. Outliers en cargos médicos

En charges se detectaron muchos valores atípicos, concentrados por encima de los 30.000 $. La mayoría de los siniestros son de bajo o moderado coste, pero un pequeño porcentaje de pacientes genera facturas extraordinariamente altas. Estos outliers son coherentes con la asimetría observada en el histograma y suelen corresponder a fumadores con obesidad o a casos de enfermedad grave.

En el modelado no se eliminaron los outliers: se consideró que forman parte de la realidad del negocio (riesgos de cola) y que el modelo de regresión lineal, aunque sensible a extremos, debe aprender también de ellos. En iteraciones futuras se podrían explorar transformaciones logarítmicas de charges o modelos más robustos.

6. Pregunta de negocio y conclusión

Pregunta formulada: *Según el índice de masa corporal, ¿qué categoría de personas ejerce mayor carga financiera a la aseguradora?*

Metodología

Se agregaron los costes totales (suma de charges) por cada categoría de bmi_category y se compararon los volúmenes y los costes medios. También se visualizó la escalada de costes a medida que aumenta el peso.

Hallazgos

- El grupo de pacientes con obesidad representa la mayor carga financiera total para la aseguradora.
- Existe una escalada directa de los costes totales a medida que aumenta el peso: el grupo de «Sobrepeso» (aprox. 4,18 M$) casi duplica el coste acumulado del grupo de «Peso normal».

- La magnitud del impacto es clara: el coste de las personas con obesidad no solo es el más alto, sino que supera ampliamente a la suma de los otros tres grupos combinados (que totalizan aproximadamente 6,66 millones de dólares).

Conclusión del EDA

- Los cargos médicos son mayoritariamente moderados, aunque existen casos aislados con costes muy elevados. En la población predominan el sobrepeso y la obesidad.
- Fumar es la variable que más encarece los gastos médicos, con una relación directa y fuerte con el aumento de costes.
- El BMI incrementa los gastos de forma moderada por sí solo, pero su efecto se dispara cuando se combina con el hábito de fumar.
- Las categorías de obesidad y sobrepeso generan la mayor carga financiera total, por el alto volumen de pacientes y por sus mayores costes individuales.
- El BMI es un factor clave, pero para predecir el coste real de un asegurado de forma precisa debe analizarse siempre en conjunto con el tabaquismo.

7. Explicación del modelo de regresión lineal

Nota: el cuaderno implementa un modelo de Regresión Lineal (no logística) para predecir la variable continua charges. A continuación se detalla el pipeline construido con PySpark MLlib.

7.1. Definición de predictores

Categóricos: sex, smoker, region
Numéricos: age, bmi, children

7.2. Pipeline de transformación

- StringIndexer: convierte las cadenas categóricas en índices numéricos (handleInvalid = «keep»).
- OneHotEncoder: transforma los índices en vectores binarios (one-hot).
- VectorAssembler: unifica todas las características (encoded + numéricas) en una sola columna vector (raw_features).
- StandardScaler: estandariza las features (media 0, varianza 1) para mejorar la estabilidad numérica del estimador.
- LinearRegression: modelo de regresión lineal con featuresCol = «features» y labelCol = «charges».

Todos los pasos se encadenan en un Pipeline de Spark MLlib, de modo que el ajuste y la transformación se aplican de forma consistente al conjunto de entrenamiento y al de prueba.

8. Explicación de la prueba y entrenamiento del modelo

Los datos se dividieron aleatoriamente en 80 % entrenamiento y 20 % prueba (randomSplit con seed = 42). El pipeline completo se ajustó sobre el conjunto de entrenamiento (pipeline.fit) y se generaron predicciones sobre el conjunto de prueba (modelo.transform).

Métricas de evaluación

Se utilizaron dos métricas estándar de regresión mediante RegressionEvaluator:

Métrica	Resultado e interpretación
RMSE (Raíz del Error Cuadrático Medio)	≈ 5.660,56 $. Error típico de predicción en la escala de los dólares de charges. Dado el rango de la variable (hasta ~64.000 $), el error es moderado.
R^2 (Coeficiente de determinación)	≈ 0,796. El modelo explica aproximadamente el 79,6 % de la varianza de los costes médicos en el conjunto de prueba.

Interpretación: un R^2 cercano a 0,80 indica un buen poder explicativo para un modelo lineal relativamente simple. El RMSE refleja que, aunque el modelo captura bien la tendencia general (especialmente el fuerte efecto del tabaquismo y del BMI), siguen existiendo residuos relevantes, en particular en los casos de costes extremos (outliers).

Las predicciones de ejemplo muestran que el modelo tiende a subestimar algunos costes bajos y a sobreestimar o subestimar de forma variable los costes altos, coherente con la asimetría de la variable objetivo y con la naturaleza lineal del estimador.

En resumen, el pipeline de regresión lineal ofrece una base sólida y interpretable para estimar charges a partir de edad, BMI, hijos, sexo, región y, sobre todo, condición de fumador. Mejoras futuras podrían incluir transformaciones de la variable objetivo, interacciones explícitas (BMI × smoker) o modelos no lineales.