ANALÍTICA ACTUARIAL & MACHINE LEARNING

Impacto del Índice de Masa Corporal en la Carga Financiera Médica

Estudio exploratorio de costes de asegurados y construcción de un pipeline de regresión predictiva con PySpark

Dataset Evaluado	Tecnología Principal	Variable Objetivo
1.338 Asegurados	**PySpark 3.5.1 & Spark ML**	**Cargos Médicos (Charges)**

VISIÓN GENERAL

Resumen Ejecutivo de la Investigación

1.338

Registros Analizados

Base de datos completa de pólizas médicas individuales.

$13.270

Gasto Promedio

Coste medio anual facturado por asegurado.

30,66

IMC Promedio

Nivel medio de masa corporal en el rango de obesidad leve.

4×

Impacto Multiplicativo

Aumento del coste al combinar IMC elevado con tabaquismo.

PROCESAMIENTO DE DATOS

Entorno PySpark y Estructura del Dataset

Entorno Distribuido

Motor de Cálculo
Apache Spark 3.5.1 sobre OpenJDK 17

API de Manipulación
`pyspark.pandas` para ingesta optimizada de CSV

Librerías Analytics
Seaborn, Matplotlib y Spark ML Pipelines

Variables de Entrada

age / sex	Edad (18–64) y Género
bmi	Índice de Masa Corporal (15.96 - 53.13)
children	Número de hijos a cargo (0 - 5)
smoker / region	Hábito tabáquico y Zona geográfica
charges	**Variable Target ($1.121 - $63.770)**

ANÁLISIS DEMOGRÁFICO

Segmentación por Índice de Masa Corporal

IMC < 18.5

Bajo Peso

$8.852

Volumen minoritario con coste promedio moderado.

18.5 – 24.9

Peso Normal

$10.409

Gasto predecible y baja dispersión de reclamos.

25.0 – 29.9

Sobrepeso

$10.994

Incremento gradual de la carga financiera total.

IMC ≥ 30.0

Obesidad

$15.562

Mayor impacto financiero absoluto sobre la aseguradora.

HALLAZGO CLAVE

Efecto Multiplicativo: Tabaquismo e IMC



Disparador de Riesgo

El IMC elevado por sí solo genera un aumento leve, pero en combinación con el tabaco multiplica el coste financiero por 5×.

INGENIERÍA DE FEATURES

Pipeline de Transformación en Spark ML

1

StringIndexer

Mapeo de variables categóricas (`sex`, `smoker`, `region`) a índices numéricos.

2

OneHotEncoder

Vectorización binaria de categorías sin establecer jerarquías falsas.

3

VectorAssembler

Unificación de `age`, `bmi`, `children` y dummies en una columna vectorial.

4

StandardScaler

Normalización con media cero y varianza unitaria para optimización.

MODELADO PREDICTIVO

Ajuste del Modelo LinearRegression en Spark

Especificación en PySpark

Implementación de `LinearRegression(featuresCol='scaledFeatures', labelCol='charges')` ensamblada dentro de un `Pipeline` unificado.

```
pipeline.fit(train_data)
```

Predicción de Carga Financiera

El modelo cuantifica la contribución marginal de cada unidad adicional de IMC y su interacción directa con la edad y el hábito tabáquico.

DESEMPEÑO DEL MODELO

Métricas de Rendimiento con RegressionEvaluator

0,75

R^2 (Coeficiente de Determinación)

75% de la varianza del coste explicada

$6.040

RMSE

Error cuadrático medio de predicción

$4.180

MAE

Error absoluto medio en dólares

Alta capacidad explicativa demostrada para tarifas estándar e identificación clara de desviación extrema en clientes de alto riesgo.

CONCLUSIONES DE NEGOCIO

Hallazgos Actuariales Principales

Umbral No Lineal

El impacto financiero del IMC se acelera drásticamente al cruzar la frontera de IMC 30.

Efecto Edad Constant

Cada año adicional incrementa el coste promedio en ~$250 de forma sostenida.

Concentración del Gasto

El segmento de fumadores con obesidad representa la mayor fuente de déficit actuarial.

ESTRATEGIA SUGERIDA

Recomendaciones Estratégicas para la Aseguradora

Tarificación Dinámica

Ajustar recargos en primas combinando los factores de IMC e historial de tabaquismo.

Programas Wellness

Incentivar económicamente la reducción de peso y la cesación tabáquica.

Scoring Predictivo

Integrar el modelo PySpark ML en el proceso de cotización y suscripción digital.

¿Preguntas sobre el Modelo?

Análisis de Riesgo en Seguros Médicos — PySpark Machine Learning

Fin de la Presentación